

Paso 1. Modalidad (Inputs/Outputs)

El asistente virtual de Matcheando un matcha seguirá una modalidad texto a texto: recibirá exclusivamente consultas escritas en texto plano y generará respuestas textuales. El caso de uso no requiere procesamiento ni generación de imágenes, audio o archivos adjuntos, por lo que estas capacidades no constituyen un requisito para la selección del modelo.

Tras revisar los modelos disponibles en OpenRouter, se descartan por modalidad:

- **Seedream 4.5:** modelo orientado a la generación de imágenes a partir de entradas de texto o imagen. Se descarta porque su salida es una imagen, mientras que el chatbot requiere generar respuestas en texto. Además, su capacidad para procesar imágenes como entrada no es necesaria para este caso de uso.
- **Gemini 3.1 Flash TTS Preview:** modelo de síntesis de voz (Text-to-Speech), cuya salida es audio y no texto.
- **Text Embedding 3 Small:** modelo de embeddings que transforma texto en representaciones vectoriales para tareas como búsqueda semántica o recuperación de información, pero no genera respuestas conversacionales en texto.

Por tanto, la búsqueda de candidatos continuará únicamente con modelos generativos capaces de producir texto, sin considerar la multimodalidad como un requisito.

Paso 2. Complejidad del razonamiento

El caso de uso se clasifica como Nivel 2 (Avanzado), aunque con una complejidad moderada dentro de este nivel. El asistente debe resolver consultas directas, pero también realizar cálculos sencillos, aplicar reglas de negocio, interpretar las necesidades del cliente para recomendar productos y mantener una interacción conversacional fluida respetando instrucciones de tono y formato.

No se requiere razonamiento profundo de Nivel 3, ya que no existen tareas de planificación compleja, programación avanzada o lógica extensa de múltiples pasos. Por ello, no es necesario recurrir a un modelo de razonamiento avanzado ni a los modelos de mayor tamaño. Un modelo ligero o estándar con suficiente capacidad de comprensión y seguimiento de instrucciones puede cubrir el caso de uso, priorizando además la baja latencia y el coste reducido exigidos por el negocio.

Paso 3. Ventana de contexto (Memoria)

No se requiere un modelo de gran contexto (>128k tokens). Las políticas de Matcheando un matcha ocupan aproximadamente 300 tokens y, aun considerando las instrucciones del sistema, la pregunta del usuario, el historial reciente de la conversación y la respuesta generada, el volumen de información es reducido.

Por tanto, una ventana de contexto baja o estándar (<32k tokens) resulta más que suficiente para este caso de uso. Las ventanas de gran contexto están orientadas a escenarios que requieren procesar grandes volúmenes de información en una misma interacción, como documentos extensos, libros o repositorios completos de código, capacidad que este chatbot no necesita.

Paso 4. Filtro de candidatos

Teniendo en cuenta la modalidad texto a texto, la complejidad moderada del razonamiento, los reducidos requisitos de contexto y, especialmente, las restricciones de baja latencia y presupuesto, se seleccionan los siguientes tres candidatos para el benchmark:

- **Gemini 2.5 Flash Lite:** modelo ligero optimizado para baja latencia y eficiencia de coste. Su orientación hacia respuestas rápidas lo convierte en un candidato especialmente adecuado para un chatbot de atención al cliente con un objetivo de respuesta inferior a dos segundos.
- **Qwen2.5 7B Instruct:** modelo de 7B parámetros orientado al seguimiento de instrucciones. Su tamaño relativamente reducido y bajo coste permiten evaluar si un modelo pequeño es capaz de alcanzar la calidad necesaria para resolver las consultas del negocio sin recurrir a modelos de mayor capacidad.
- **Mistral Small 3:** modelo de 24B parámetros optimizado para baja latencia y con un coste de inferencia reducido. Permite incorporar al benchmark un candidato de mayor capacidad manteniendo las restricciones de velocidad y presupuesto del caso de negocio.

Esta selección permite comparar modelos con diferentes tamaños y características para comprobar experimentalmente cuál ofrece el mejor equilibrio entre calidad, velocidad y coste, en lugar de asumir que el modelo de mayor capacidad será necesariamente la mejor opción.

Matriz de Evaluación y Decisión Final

Pregunta 5:

Es mi primera compra. Quiero 1 Matcha Ceremonial, 1 Matcha Culinario y 1 Batidor de Bambú y voy a utilizar el código PRIMERMATCHA. ¿Cuál es el precio final con el descuento y tengo que pagar gastos de envío?

Pregunta 6:

He visto que vendéis Matcha Ceremonial con sabor a vainilla. ¿Cuánto cuesta y qué cantidad viene en cada bote?

Pregunta 7:

I'm new to matcha and I'd like something for baking. Could you recommend a product and explain how I should prepare it? Please answer in English in a friendly and concise tone.

Pregunta 8:

Hola! Estoy pensando en empezar a tomar matcha porque últimamente estoy intentando cambiar un poco mis desayunos. Normalmente por las mañanas voy bastante deprisa y suelo prepararme un batido con leche vegetal, plátano y avena antes de salir de casa. Una amiga me habló del matcha y me dijo que hay distintos tipos, pero nunca lo he probado y no sé muy bien cuál elegir. He estado mirando vuestra tienda y veo que tenéis varias opciones, aunque de momento no necesito ningún accesorio. Por cierto, vivo en la península y no tengo ninguna prisa especial con el pedido. Con todo esto, ¿qué matcha me recomendáis para mis batidos y cuánto cuesta?

Criterio de evaluación	Gemini 2.5 Flash Lite	Qwen2.5 7B Instruct	Mistral Small 3
P1 (Cálculo): Suma correcta y Envío Gratis	Sí	Sí	Sí
P2 (Trampa): Evitó inventar y dio email	Sí	Sí	Sí
P3 (Recomendación): Culinario + 80°C	Sí	Sí	Sí
P4 (Formato): Exactamente 2 frases	Sí	Sí	Sí
P5 (Cálculo Propio): Descuento y precio final correctos	Sí	No	Sí
P6 (Trampa Propia): Sin alucinaciones	Sí	Sí	Sí
P7 (Tono/Idioma): Adaptación correcta	Sí	Sí	Sí
P8 (Caso Complejo): Síntesis precisa	Sí	No	No
Velocidad de Respuesta Percibida	Rápido	Rápido	Rápido
Puntuación Global (1 al 5)	5/5	3/5	4/5

Recomendación Final de Negocio

Recomendaría Gemini 2.5 Flash Lite, ya que ha obtenido los mejores resultados globales en el benchmark, respondiendo correctamente a las 8 pruebas y mostrando buena precisión en los cálculos, control de alucinaciones y seguimiento de instrucciones. Además, ha ofrecido respuestas rápidas y concisas, manteniendo un coste bajo por interacción. Aunque Mistral Small 3 presentó un coste inferior, Gemini ofrece en este caso el mejor equilibrio entre calidad, velocidad y coste para el asistente de Matcheando un matcha.